TEMPLATE PROPOSAL PENGAJUAN TUGAS AKHIR

Maksimal 4 halaman A4. Template ini fleksibel; penulis boleh mengembangkan struktur/isi sesuai kebutuhan topik dan bentuk TA.

Judul usulan TA	: Evaluasi Kinerja Random Forest dengan SMOTE-Tomek pada Klasifikasi Aktuator Penambah Nutrisi Sistem IoT Hidroponik
Bentuk TA	: Laporan Akhir TA
Nama mahasiswa	: Habbi Widagdo
NIM	: 123140204
Kelompok/anggota (Jika Ada)	: -
Dosen pembimbing usulan	: Amirul Iqbal, S.Kom., M.Eng.
Mitra/instansi (jika ada)	: -
Luaran utama yang ditargetkan	: Hasil evaluasi model klasifikasi dalam menghadapi dataset yang tidak seimbang dengan menggunakan teknik *Smote-tomek*
Semester pengajuan	: 7

Petunjuk Singkat

- Template ini dipakai untuk semua bentuk Tugas Akhir: Laporan TA, Capstone Design, Publikasi Ilmiah, HKI/Paten, TTG, dan Buku ber-ISBN.
- Panjang proposal maksimal 4 halaman A4. Gunakan bahasa Indonesia baku; istilah teknis Inggris boleh bila perlu.
- Template ini tidak membatasi pengembangan isi. Anda boleh menambah subbagian, tabel, gambar, atau uraian lain selama tetap relevan dan tidak melampaui batas halaman.
- Untuk TA berbasis Laporan TA, penting untuk mengulas state of the art dari riset yang akan dilakukan agar posisi usulan dan kebaruan/kontribusinya jelas.
- Untuk bentuk berbasis tim/mitra, jelaskan kontribusi individu, identitas mitra, serta ruang lingkup kerja masing-masing mahasiswa.
- Hapus semua teks petunjuk/contoh sebelum submit proposal final.

Penyesuaian per Bentuk TA

Bentuk TA	Fokus proposal	Bukti/luaran awal yang relevan
1. Laporan TA	Masalah, tujuan, metode, rencana eksperimen/pembangunan sistem, serta state of the art riset yang diusulkan.	Objek/data awal, referensi inti, ringkasan state of the art, rencana Bab I–III.
2. Capstone Design	Masalah mitra, kebutuhan sistem, peran individu, deliverable tim.	Profil mitra, ruang lingkup tim, pembagian kontribusi.
3. Publikasi Ilmiah	Research question, novelty, target venue, rencana artikel.	Daftar target jurnal/konferensi, outline artikel.
4. HKI/Paten	Produk/invensi, kebaruan, TKT awal, strategi pengajuan HKI.	Draf klaim/deskripsi invensi, status prototipe TKT ≥3.
5. TTG	Masalah lapangan, solusi terapan, adopsi mitra, evaluasi manfaat.	Mitra formal, rencana implementasi, indikator dampak.
6. Buku ISBN	Tema buku, basis kajian ilmiah/PRISMA, struktur bab, sasaran pembaca.	Protokol PRISMA, outline buku, narasi ilmiah singkat.

1. Latar Belakang dan Rumusan Masalah

IoT adalah interkoneksi perangkat komputasi yang mengirimkan data ke *cloud* [1]. Pertanian presisi menggunakan sistem sensor IoT berskala besar agar sistem dapat beroperasi secara efisien, untuk mengawasi kondisi tanaman dan lingkungan serta memicu tindakan yang tepat pada waktu yang tepat [1], [2]. Namun, data yang dihasilkan sensor tersebut berpotensi menghadirkan tantangan karakteristik data mentah yang kompleks.

Tantangan pada data mentah ini tergambar jelas pada dataset *Hydroponics* yang dipublikasi oleh Moniruzzaman (2025) memuat data telemetri deret waktu (*time-series*) mentah dari sistem hidroponik berskala kecil. Data tersebut mencakup pembacaan sensor kimia air dan lingkungan, serta status aktuator yang bernilai ON atau OFF. Dataset seperti ini terdapat nilai-nilai yang tidak wajar dan sifat operasional aktuator yang statis menghasilkan data kelas yang sangat tidak seimbang dengan rasio 94% OFF dan 6% ON [3]. Kendala seperti perangkat sensor dan lingkungan yang ekstrem mempengaruhi perolehan data menjadi anomali atau *outlier* [4].

Hal tersebut meningkatkan potensi performa yang didapatkan model. Dalam pengujian model *Random Forest* terhadap klasifikasi dataset kelas yang tidak seimbang atau *imbalance* tanpa menggunakan teknik penanganan *data imbalanced* menghasilkan akurasi sebesar 87.7% yang terlihat cukup tinggi, namun ini terdapat *misleading* karena *imbalance* dalam kelas bisa membuat model klasifikasi menjadi bias dan lebih mementingkan kelas mayoritas, sehingga hasil klasifikasi untuk kelas minoritas cenderung gagal [5], [6]. Terlihat dari nilai *balanced accuracy* sebesar 78.5% yang didapatkan dari hasil perhitungan rata-rata *sensitivity* atau kemampuan model mendeteksi kelas minoritas dan *specificity* atau kemampuan model mendeteksi kelas mayoritas [6]. Kondisi ini terbukti menurunkan kinerja model klasifikasi, sebagaimana yang ditemukan dalam *Systematic Literature Review* (SLR) yang dilakukan Miftahushudur et al. menjabarkan bukti konkret kerugian yang diakibatkan oleh *imbalance* data seperti tanaman mati karena kegagalan model dalam mendeteksi atau memprediksi label yang ditentukan [4]. Oleh karena itu, diperlukan teknik khusus pada tahap pra-pemrosesan atau pemodelan untuk menangani bias tersebut.

Pada penelitian klasifikasi korban kecelakaan mobil yang mengalami cedera atau tidak, terbukti model *Random Forest* lebih unggul dibandingkan model *SVM, AdaBoost, dan Logistic regression* dengan menggunakan metode penanganan di tingkat data (*data-level resampling*) yaitu metode pengurangan sampel seperti algoritma *Random Under-Sampling* (RUS) dan metode sintesis sampel seperti algoritma *Synthetic Minority Over-sampling Technique* (SMOTE) [6]. Namun, kedua teknik ini sering diperdebatkan efektivitasnya. Di satu sisi, penerapan RUS terbukti mampu menyeimbangkan distribusi data secara cepat, namun teknik ini membawa konsekuensi negatif berupa hilangnya pola penting kelas mayoritas [7]. Di sisi lain, SMOTE hadir dengan menyintesis sampel baru untuk mencegah data minoritas yang berharga dianggap sebagai gangguan dan dibuang begitu saja dari model [8]. Namun, kelemahan SMOTE yaitu manipulasi data secara sintetis menggunakan algoritma ini sering kali memicu risiko tumpang tindih data (*overlapped data*) di dekat batas keputusan kelas mayoritas yang justru menurunkan performa klasifikasi secara keseluruhan [4]. Guna mengatasi keterbatasan kedua teknik konvensional tersebut, Asif et al., merekomendasikan penerapan teknik hibrida seperti algoritma *Smote-tomek*

dikombinasikan dengan model *Random Forest*, terbukti secara konsisten memberikan keseimbangan terbaik dalam mengenali kelas minoritas tanpa mengorbankan performa klasifikasi kelas mayoritas [9]. Namun, teknik hibrida (*Smote-tomek*) secara spesifik pada log sensor aktuator IoT hidroponik mentah (*raw time-series*) dengan tingkat ketimpangan ekstrem belum dieksplorasi. Sebagian besar penelitian penanganan data *imbalance* di sektor pertanian presisi masih berfokus pada deteksi penyakit tanaman, pengelolaan tanah, dan klasifikasi jenis tanaman [4], sehingga menjadi celah penelitian (*research gap*) utama yang akan diselesaikan dalam penelitian ini.

Berdasarkan celah tersebut, penelitian ini akan melakukan komparasi antara kualitas model sebelum dan sesudah menangani *imbalance* data dengan menggunakan teknik penanganan di tingkat data yaitu algoritma *Smote-tomek* dan menggunakan model *Random Forest* untuk klasifikasi status aktuator, serta menggunakan dataset *Hydroponics* dari Moniruzzaman (2025) yang terbukti mengalami *imbalance* data kelas. Pada tahap evaluasi akan menggunakan indikator yang digunakan Asif et al,. dalam evaluasi performa model dalam menangani klasifikasi dan dataset yang tidak seimbang diantaranya *Accuracy, Precision, Recall, dan F1-Score* [9].

Rumusan Masalah

1. Bagaimana penerapan kombinasi algoritma Random Forest dan teknik *resampling Smote-tomek* dalam mengklasifikasikan status aktuator pada dataset sensor IoT hidroponik yang ekstrem tidak seimbang?
2. Bagaimana perbandingan performa model klasifikasi Random Forest (berdasarkan metrik *Accuracy, Precision, Recall, dan F1-Score*) antara data yang tidak diberikan perlakuan *imbalance* dengan data yang ditangani menggunakan *Smote-tomek*?

2. Tujuan dan Manfaat

Tujuan

1. Menerapkan dan mengevaluasi kinerja algoritma Random Forest dalam mengklasifikasikan status aktuator hidroponik menggunakan teknik penanganan data *imbalance* algoritma *Smote-tomek*.
2. Menganalisis perbandingan efektivitas model klasifikasi sebelum dan sesudah penerapan algoritma *Smote-tomek* berdasarkan metrik evaluasi yang berfokus pada kelas minoritas (*Accuracy, Precision, Recall, dan F1-Score*).

Manfaat

1. Akademik
   Penelitian ini diharapkan dapat memberikan bukti empiris terkait efektivitas penerapan metode hibrida *resampling Smote-tomek* yang dipadukan dengan model *Random Forest* dalam mengatasi ketidakseimbangan kelas (*class imbalance*) yang ekstrem pada dataset deret waktu mentah. Menjadi rujukan dan landasan teori bagi sivitas akademika, khususnya

di lingkungan Program Studi Teknik Informatika ITERA, yang ingin mendalami eksplorasi *data science*, penanganan data anomali sensor, serta implementasi kecerdasan buatan pada sektor pertanian presisi.

2. Praktis
   Memberikan alur kerja pemrosesan data yang teruji bagi pengembang sistem IoT dan pengembang perangkat lunak dalam menangani *noise* serta ketimpangan data sensor sebelum diimplementasikan ke dalam sistem otomasi. Membantu praktisi pertanian cerdas (*smart agriculture*) menekan risiko kegagalan sistem otomasi aktuator. Dengan klasifikasi kelas aktuator yang lebih akurat, sistem dapat mendeteksi momen kritis penambahan nutrisi secara presisi, sehingga meminimalisasi risiko tanaman mati atau gagal panen akibat defisiensi nutrisi.

3. Tinjauan Singkat / Dasar Ilmiah / State of the Art

3.1 Tinjauan Singkat Studi Terdahulu

Penelitian Pius et al., telah membuktikan penerapan model *Random Forest* untuk klasifikasi kebutuhan irigasi atau tidak pada jenis tanaman gandum yang diintegrasikan dengan IoT dan perangkat *edge* di lapangan menghasilkan performa yang optimal. Untuk melatih dan memvalidasi model klasifikasi yang akan dikembangkan, digunakan dataset awal dari Kaggle berupa kelembapan dan suhu untuk tanaman kapas sebanyak 500 entri, namun peneliti memodifikasi dan menyesuaikan skala nilai suhu dan irigasi tersebut, agar selaras dengan kebutuhan tanaman gandum, serta memperluas dengan membuat data sintesis hingga 5000 entri. Berdasarakn *Confusion Matrix,* model *random forest* menghasilkan distribusi kelas yang cenderung seimbang dimana kelas "*No Irrigation*" sebanyak 433 dan kelas "*Irrigation*" sebanyak 567 [10]. Sehingga penelitian ini tidak membutuhkan teknik penanganan *imbalance* data. Hal tersebut tidak mengambarkan kondisi nyata dari tantangan dataset mentah yang dihasilkan oleh perangkat *edge,* seperti yang digambarkan dalam dataset *Hydroponics* yang dipublikasi oleh Moniruzzaman (2025) memuat data telemetri deret waktu (*time-series*) dan kondisi aktuator yang belum diolah dari sistem hidroponik berskala kecil [3].

Sehingga dibutuhkan metode penanganan *data imbalanced* untuk menghasilkan model klasifikasi yang tangguh. Terdapat dua teknik yang umum digunakan dalam penanganan *data imbalance,* yaitu metode RUS terbukti mampu menyeimbangkan distribusi data secara cepat, namun teknik ini membawa konsekuensi berupa hilangnya pola penting kelas mayoritas [7]. Selanjutnya metode SMOTE membuat sampel baru untuk mencegah data minoritas yang berharga dianggap sebagai gangguan dan dibuang begitu saja oleh model [8]. Namun, kelemahan SMOTE yaitu manipulasi data secara sintetis menggunakan algoritma ini sering kali memicu risiko *overlapped data* di dekat batas keputusan kelas mayoritas yang justru menurunkan performa klasifikasi secara keseluruhan [4]. Guna mengatasi keterbatasan kedua teknik konvensional tersebut, Asif et al., merekomendasikan penerapan teknik hibrida seperti *Smote-tomek* dikombinasikan dengan model *Random Forest*, yang terbukti secara konsisten memberikan

keseimbangan terbaik dalam mengenali kelas minoritas tanpa mengorbankan performa klasifikasi kelas mayoritas [9].

Namun, teknik hibrida (*Smote-tomek*) secara spesifik pada log sensor aktuator IoT hidroponik mentah (*raw time-series*) dengan tingkat ketimpangan ekstrem belum dieksplorasi. Sebagian besar penelitian penanganan *data imbalanced* di sektor pertanian presisi masih berfokus pada deteksi penyakit tanaman, pengelolaan tanah, dan klasifikasi jenis tanaman [4]. Maka dari itu, penelitian ini akan menguji penerapan metode *Smote-tomek* dalam penanganan *imbalanced* data kelas kondisi aktuator *ON* atau *OFF* dari dataset *Hydroponics* Moniruzzaman (2025) untuk meningkatkan performa model *Random Forest* dalam klasifikasi.

3.2 Landasan Teori

3.2.1 Class Imbalance

Pada dataset kelas yang tidak seimbang *(imbalance)* yang digunakan untuk melatih dan menguji model klasifikasi dapat menybabkan bias, dimana model lebih mementingkan yang memiliki jumlah data kelas lebih banyak atau mayoritas dibandingkan kelas yang memiliki jumlah jauh lebih sedikit atau minoritas. Hal tersebut mengakibatkan model terbiasa terhadap klasifikasi data kelas mayoritas dan cenderung gagal klasifikasi kelas minoritas ketika diterapkan pada sistem dengan menggunakan data mentah untuk atau sistem pengumpulan data *real-time* berbasis IoT [5].

3.2.2 Teknik Resampling *Smote-tomek*

3.2.2.1 SMOTE

Algoritma *Synthetic Minority Over-sampling Technique* (*SMOTE*) mengatasi masalah ketidakseimbangan kelas dengan cara beroperasi pada ruang fitur (*feature space*) untuk menghasilkan sampel sintetis baru, alih-alih sekadar menyalin atau mereplikasi data yang sudah ada. Cara kerjanya adalah dengan mengambil setiap sampel dari kelas minoritas dan memperkenalkan contoh data sintetis baru di sepanjang segmen garis yang menghubungkan sampel tersebut dengan tetangga terdekat (*k-nearest neighbors*) kelas minoritasnya. Secara teknis, sampel sintetis diciptakan dengan menghitung selisih antara vektor fitur sampel yang sedang dianalisis dan tetangga terdekat yang terpilih, mengalikan selisih tersebut dengan angka acak antara 0 dan 1, lalu menjumlahkan hasilnya kembali ke vektor fitur sampel awal. Pendekatan ini menghasilkan titik acak baru di sepanjang garis penghubung kedua fitur tersebut, yang secara efektif memperluas wilayah keputusan (*decision region*) kelas minoritas menjadi lebih luas dan umum, sehingga membantu algoritma klasifikasi untuk melakukan generalisasi dengan lebih baik [11].

3.2.2.2 Tomek Links

Dalam mengatasi permasalahan ketidakseimbangan kelas (*class imbalance*), algoritma *Tomek Links* dapat diterapkan baik sebagai teknik *under-sampling* maupun sebagai metode pembersihan data (*data cleaning*). Secara matematis, sepasang sampel E_i dan E_j yang berasal dari kelas berbeda dikategorikan sebagai *Tomek Link* jika tidak terdapat sampel ketiga (E_l) yang posisinya lebih dekat ke E_i maupun E_j dibandingkan jarak antara kedua sampel tersebut. Kemunculan pasangan *Tomek Link* ini mengindikasikan bahwa salah satu sampel merupakan *noise* atau kedua sampel tersebut saling tumpang tindih di sekitar batas keputusan (*borderline*). Ketika difungsikan sebagai metode

under-sampling, algoritma ini akan membersihkan data dengan cara membuang hanya sampel yang berasal dari kelas mayoritas dari pasangan tersebut. Sementara itu, jika diterapkan sebagai metode *data cleaning*, sampel dari kedua kelas (baik mayoritas maupun minoritas) yang membentuk pasangan *Tomek Link* akan dieliminasi untuk menghasilkan batas keputusan yang lebih bersih dan tegas [12].

3.2.2.3 *Smote-tomek*

Masalah ketidakseimbangan kelas (*class imbalance*) dan tumpang tindih data (*class overlapping*) dapat diatasi secara efektif menggunakan metode hibrida *SMOTE* dan *Tomek links* yang mengombinasikan teknik peningkatan sampel (*over-sampling*) dan pembersihan data (*data cleaning*). Algoritma ini bekerja dengan menerapkan metode *SMOTE* terlebih dahulu untuk menyeimbangkan distribusi data melalui interpolasi sampel sintetis di antara data kelas minoritas yang saling berdekmatan [11],[13]. Guna mengatasi kelemahan *SMOTE* yang sering kali memperluas klaster minoritas terlalu jauh hingga menginvasi ruang kelas mayoritas yang rentan memicu *overfitting*, metode *Tomek links* kemudian diaplikasikan untuk mengidentifikasi dan menghapus pasangan data dari kedua kelas yang saling tumpang tindih di batas keputusan [12], [13]. Kombinasi ini terbukti krusial karena berhasil mengeliminasi data *noise* yang berada di sisi batas keputusan yang salah, sehingga menghasilkan klaster kelas yang terdefinisi dengan jelas (*better-defined class clusters*) serta memungkinkan pembentukan model klasifikasi yang lebih sederhana dengan kemampuan generalisasi yang lebih optimal [13].

4. Metode / Rencana Pelaksanaan

4.1 Pendekatan Penelitian

4.1.1 Jenis Penelitian

Penelitian ini akan menggunakan jenis kuantitatif karena akan melakukan pengukuran metrik numerik dan uji coba modifikasi data menggunakan algoritma.

4.1.2 Desain Eksperimen

Penelitian ini akan menggunakan pendekatan perbandingan atau komparatif, yaitu membandingkan performa dua skenario model:

1. Model klasifikasi *Random Forest* dilatih dengan data asli dengan kondisi tidak seimbang.
2. Model klasifikasi *Random Forest* dilatih dengan data yang telah diseimbangkan dengan algoritma *SMOTE-Tomek*.

4.2 Bahan dan Alat

4.2.1 Dataset Penelitian

Data yang digunakan dalam penelitian ini adalah dataset sekunder bersifat publik yang berjudul "*Hydroponic IoT Sensor & Actuator Logs (Raw)*" yang diekstraksi dari platform Kaggle. Dataset ini memuat data telemetri deret waktu (*time-series*) mentah yang direkam dari node IoT (kelas Arduino/ESP) pada sebuah sistem hidroponik berskala kecil [3].

Pengambilan data (perekaman) dilakukan selama satu bulan operasional, terhitung sejak 26 November 2023 hingga 26 Desember 2023. Dataset ini terdiri dari satu file format *Comma Separated Values* (CSV) bernama *IoTData --Raw--.csv* yang memiliki total 50.570 baris (*rows*) dan 13 kolom (*columns*) [3].

Struktur variabel atau atribut di dalam dataset ini dibagi menjadi fitur lingkungan (sebagai variabel independen) dan status aktuator (sebagai variabel dependen). Rincian atribut data ditunjukkan pada Tabel 4.1.

Tabel 4.1 Deskripsi Atribut Dataset *Hydroponic IoT Sensor*

Nama Atribut	Tipe Data	Keterangan
id	Integer	Nomor identitas baris data.
timestamp	String (ISO 8601)	Waktu perekaman data secara lokal oleh perangkat.
pH	Float	Tingkat keasaman/kebasaan larutan nutrisi air.
TDS	Float (ppm)	Total Dissolved Solids, konsentrasi nutrisi terlarut dalam air.
water_level	Integer (0–3)	Indikator volume ketinggian air secara diskrit (0=kosong, 3=penuh).
DHT_temp	Float (°C)	Suhu udara di sekitar wadah/penampungan hidroponik.
DHT_humidity	Float (% RH)	Tingkat kelembapan udara relatif.
water_temp	Float (°C)	Suhu air di dalam wadah penampungan.
pH_reducer	Kategorikal (ON/OFF)	Status aktuator pompa penurun pH air.
add_water	Kategorikal (ON/OFF)	Status aktuator pompa penambah air.
nutrients_adder	Kategorikal (ON/OFF)	Status aktuator pompa penambah nutrisi (Variabel Target/Label).
humidifier	Kategorikal (ON/OFF)	Status aktuator pelembap udara.
ex_fan	Kategorikal (ON/OFF)	Status aktuator kipas pembuangan udara.

4.2.2 Perangkat Penelitian

Pada penelitian ini adapun perangkat lunak dan keras yang digunakan adalah.

1. Google Colab

2. Laptop Lenovo LOQ Essential
3. Bahasa pemrograman Python

4.3 Tahapan Penelitian



Gambar 4.1 Diagram Alur Penelitian

4.4 Metode Analisis dan Evaluasi

4.4.1 Pengujian Model

Pada tahap ini model akan diuji dengan menggunakan dataset yang telah dibagi sebelumnya untuk melakukan prediksi yang dibagi dua skenario pengujian, yaitu:

1. Menggunakan dataset asli tanpa penanganan *imbalance data.*
2. Menggunakan dataset yang telah melalui penanganan *imbalance data*.

4.4.2 Perhitungan Metrik Evaluasi

4.4.2.1 Menghitung *Confusion Matrix*

Confusion Matrix digunakan untuk membantu menentukan empat parameter yang menjadi dasar untuk menghitung metrik lainnya, yaitu *True Positive* (TP), *False Positive* (FP), *False Negative* (FN), dan *True Negative* (TN). Matriks ini dapat disusun setelah model melakukan tugas klasifikasi dengan membandingkan seluruh sampel yang telah diklasifikasikan dengan kelas aslinya (yang sudah kita ketahui) [14].

Tabel 4.2 *Confusion Matrix*

	Actual positive	*Actual Negative*
Predicted positive	*TP*	*FP*
Predicted negative	*FN*	*TN*

4.4.2.2 Menghitung *Accuracy*

Metrik Akurasi adalah metrik untuk mengukur jumlah prediksi yang benar sebagai persentase dari total jumlah prediksi yang dibuat model klasifikasi [14].

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

4.4.2.3 Menghitung *Precision*

Metrik *Precision* menekankan pada identifikasi kelas positif secara akurat, dengan mengukur kemungkinan penentuan nilai positif yang tepat. Secara khusus, metrik ini menghitung proporsi *true positive* (positif yang sebenarnya) dari keseluruhan sampel yang dilabeli sebagai positif oleh model. Perlu dicatat bahwa presisi tidak terpengaruh oleh dominasi sampel negatif, sehingga menyoroti relevansinya dalam situasi yang melibatkan ketidakseimbangan kelas *(class imbalance)* [14].

$$Precision = \frac{TP}{TP + FP}$$

4.4.2.4 Menghitung *Recall*

Dalam *machine learning*, metrik *Recall* mengukur kemampuan model untuk mengidentifikasi kasus positif secara tepat. Metrik ini sering disebut sebagai *true positive rate* (TPR) atau *sensitivity* yang menyoroti kemampuan model dalam mengenali sampel positif secara akurat [14].

$$Recall = \frac{TP}{TP + FN}$$

4.4.2.4 Menghitung *F1-score*

F1-score didefinisikan sebagai rata-rata dari *precision* dan *recall*, karena skor ini menggabungkan metrik *precision* dan *recall* menjadi satu metrik tunggal, dengan memberikan bobot yang sama pada keduanya [14].

$$F1\text{-}score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

4.4.3 Analisis Komparatif

Pada tahap ini akan dilakukan perhitungan selisih nilai metrik dari kedua skenario untuk menarik hasil analisis dan kesimpulan apakah algoritma *SMOTE-Tomek* berhasil meningkatkan performa klasifikasi pada kelas minoritas (ON).

5. Luaran yang Ditargetkan

Luaran utama dan indikator tercapai atau berhasilnya Tugas Akhir berupa:

1. Hasil eksperimen dan analisisnya
2. Laporan Tugas Akhir

6. Jadwal Ringkas

Rancangan jadwal penelitian sementara dapat dilihat pada diagram Gantt Chart berikut.

Tabel 6.1 *Gantt Chart* jadwal penelitian

No	Kegiatan	Bulan 1				Bulan 2				Bulan 3				Bulan 4				Bulan 5				Bulan 6				Bulan 7			
		M1.1	M1.2	M1.3	M1.4	M2.1	M2.2	M2.3	M2.4	M3.1	M3.2	M3.3	M3.4	M4.1	M4.2	M4.3	M4.4	M5.1	M5.2	M5.3	M5.4	M6.1	M6.2	M6.3	M6.4	M7.1	M7.2	M7.3	M7.4
1	Studi literatur & penyusunan BAB I-III																												
2	Bimbingan proposal																												
3	Seminar proposal																												
4	Pengumpulan dan pra-pemrosesan data																												
5	Penanganan imbalance data																												
6	Pelatihan model																												
8	Evaluasi pengujian																												
10	Analisis hasil dan penyusunan BAB IV-V																												
11	Bimbingan hasil dan revisi																												
12	Seminar hasil																												
13	Bimbingan dan revisi																												
14	Sidang akhir																												
15	Bimbingan dan revisi final																												

Ket:

M = Bulan

Mx.x = Minggu

7. Referensi Inti

[1] K. N. Bhanu, H. S. Mahadevaswamy, and H. J. Jasmine, "IoT based Smart System for Enhanced Irrigation in Agriculture," *Proc. Int. Conf. Electron. Sustain. Commun. Syst. ICESC 2020*, no. Icesc, pp. 760–765, 2020, doi: 10.1109/ICESC48915.2020.9156026.

[2] G. A. M. Abdullah, N. A. M. Alduais, and M. R. Arshad, "A Comparative Study of Machine Learning Models for Real-Time IoT- based Soil Moisture Anomaly Detection," *Proc. Int. Colloq. Signal Process. Its Appl. CSPA*, vol. 2026-May, no. 2026, pp. 236–241, 2026, doi: 10.1109/CSPA68262.2026.11517729.

[3] Moniruzzaman, "Hydroponic IoT Sensor and Actuator Logs," kaggle. Accessed: Aug. 08, 2026. [Online]. Available: https://www.kaggle.com/datasets/itsmonir31/hydroponics-datasets

[4] T. Miftahushudur, H. M. Sahin, B. Grieve, and H. Yin, "A Survey of Methods for Addressing Imbalance Data Problems in Agriculture Applications," *Remote Sens.*, vol. 17, no. 3, pp. 1–31, 2025, doi: 10.3390/rs17030454.

[5] S. Calin, "Handling Imbalanced Data: The SMOTE Technique," *Proc. 2025 17th Int. Conf. Electron. Comput. Artif. Intell. ECAI 2025*, pp. 1–5, 2025, doi: 10.1109/ECAI65401.2025.11095450.

[6] S. Nguyen *et al.*, "Detecting Non-Injured Passengers and Drivers in Car Accidents: a New Under-Resampling Method for Imbalanced Classification," *Adv. Bus. Manag. Forecast.*, vol. 13, pp. 93–105, 2019, doi: 10.1108/S1477-407020190000013011.

[7] S. Kotsiantis, D. Kanellopoulos, and P. Pintelas, "Handling imbalanced datasets : A review," *Science (80-.).*, vol. 30, no. 1, pp. 25–36, 2006, [Online]. Available: http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.96.9248&rep=rep1&type=pdf

[8] A. S. More and D. P. Rana, "An Experimental Assessment of Random Forest Classification Performance Improvisation with Sampling and Stage Wise Success Rate Calculation," *Procedia Comput. Sci.*, vol. 167, no. Iccids 2019, pp. 1711–1721, 2020, doi: 10.1016/j.procs.2020.03.381.

[9] M. Asif, J. A. Bhatti, M. Safwan, M. R. Khan, F. A. Siddiqui, and M. Rehan, "A Comparative Analysis of Resampling Techniques for Addressing Class Imbalance in Multiclass Classification," *7th Ed. Glob. Conf. Wirel. Opt. Technol. GCWOT 2024*, pp. 1–6, 2024, doi: 10.1109/GCWOT63882.2024.10805619.

[10] A. A. Pius, R. M. Sino, D. James, E. Santhosh, and M. P. Rohith, "Sustania: A Digital Farming Ecosystem for Smart Agriculture," *Proc. ACCTHPA 2025 - Conf. 2025 Adv. Comput. Commun. Technol. High Perform. Appl.*, pp. 1–8, 2025, doi: 10.1109/ACCTHPA65749.2025.11168623.

[11] H. Mansourifar and W. Shi, “Deep Synthetic Minority Over-Sampling Technique,” vol. 16, pp. 321–357, 2020, [Online]. Available: http://arxiv.org/abs/2003.09788

[12] I. Tomek, “Tomek - 1976 - TWO MODIFICATIONS OF CNN,” pp. 769–772, 1976.

[13] G. E. A. P. A. Batista, R. C. Prati, and M. C. Monard, “A study of the behavior of several methods for balancing machine learning training data,” *ACM SIGKDD Explor. Newsl.*, vol. 6, no. 1, pp. 20–29, 2004, doi: 10.1145/1007730.1007735.

[14] A. de Giorgio, G. Cola, and L. Wang, “Systematic review of class imbalance problems in manufacturing,” *J. Manuf. Syst.*, vol. 71, no. November, pp. 620–644, 2023, doi: 10.1016/j.jmsy.2023.10.014.

8. Lampiran Ringkas Khusus Bentuk TA (bila relevan)

- Capstone/TTG: identitas mitra, kebutuhan awal, pembagian tugas individu.
- Publikasi: target venue, outline artikel, posisi novelty.
- HKI/Paten: deskripsi invensi, kebaruan, status prototipe/TKT awal.
- Buku ber-ISBN: outline buku, sasaran pembaca, protokol PRISMA/ringkasan kajian.

Catatan Akhir

Proposal ini adalah template dasar pengajuan TA. Struktur boleh disesuaikan dan diperdalam menurut karakter topik, arahan calon pembimbing, kebutuhan mitra, dan bentuk luaran yang ditargetkan.